

## Analyse Multivariée

### TP n°2: Analyse Discriminante PLS exploratoire

#### I - Théorie

On considère deux matrices de données décrivant  $n$  individus (en ligne) :  $X = [x^1, \dots, x^p]$  codant  $p$  variables numériques centrées ;  $Y = [y^1, \dots, y^q]$  codant une variable qualitative à  $q$  modalités par ses indicatrices non centrées. On note  $W = \text{diag}(w_i; i=1, \dots, n)$  la matrice des poids des individus. L'espace  $\mathbb{R}^p$  est muni de la métrique d'ACP de  $X$ , notée  $M$ .

On rappelle que l'ADPLS est fondée sur la maximisation par chaque composante  $f = XMu$  du critère produit :  $\|f\|_W^2 R^2(f, Y)$  sous la contrainte  $u'Mu = 1$ .

1. Montrez que :  $\|f\|_W^2 R^2(f, Y) = \|\hat{X}Mu\|_W^2$ , où  $\hat{X} = \Pi_Y X$ .

2. Programme de rang 1 :

a) Soit la matrice  $E = \hat{X}'W\hat{X}$ . Interprétez-la.

b) Soit le programme :  $\max_{u'Mu=1} \|\hat{X}Mu\|_W^2$ , dont la solution fournit la première composante  $f^1$ .

Montrez que  $f^1 = XMu_1$ , où  $u_1$  est le vecteur propre  $M$ -unitaire de  $EM$  associé à sa plus grande valeur propre.

b) Montrez que si l'on pose  $u^* = M^{1/2}u$ ,  $X^* = XM^{1/2}$  et  $\hat{X}^* = \Pi_Y X^*$ ,  $u_1^*$  est le vecteur propre  $I$ -unitaire de la matrice symétrique  $E^* = \hat{X}^{*'}W\hat{X}^*$  associé à sa plus grande valeur propre. Montrez qu'alors,  $f^1 = X^*u_1^*$ .

3. Programme de rang  $h$  :

On désire obtenir des composantes deux à deux orthogonales. On note  $F^{h-1} = [f^1, \dots, f^{h-1}]$ . La  $h$ -ième composante  $f^h$  doit donc vérifier la contrainte d'orthogonalité :  $F^{h-1}'Wf^h = 0$ .

a) Montrez que la résolution du programme  $\max_{\substack{u'Mu=1 \\ D'Mu=0}} u'MEMu$ , où  $D' = F^{h-1}'WX$ ,

conduit à rechercher  $u$  solution de :

$$\Pi_{D^\perp} EMu = \lambda u \quad (5), \text{ où } \Pi_{D^\perp} = I - D(D'MD)^{-1}D'M \text{ et } \lambda \text{ maximale.}$$

b) Montrez qu'alors,  $u \in \langle D^\perp \rangle$ . Déduisez-en que  $u$  est de façon équivalente solution de :

$$\Pi_{D^\perp} EM \Pi_{D^\perp} u = \lambda u \text{ associé à } \lambda \text{ maximale.}$$

c) Montrez que cette dernière équation équivaut à :

$$M^{1/2} \Pi_{D^\perp} \hat{X}'W\hat{X} \Pi_{D^\perp} M^{1/2} u^* = \lambda u^*,$$

qui caractérise la diagonalisation d'une matrice symétrique.

4. Pour toute composante discriminante  $f$ , interprétez les deux indicateurs suivants :

$$S(f) = \frac{\|f\|_W^2}{\text{tr}(X'WX)} ; \quad R^2(f, Y) = \frac{\|\hat{X}Mu\|_W^2}{\|f\|_W^2}$$

### 5. Représentations graphiques :

Dans le plan  $(h, m)$  direct, l'individu  $i$  sera représenté par ses coordonnées selon les composantes réduites :  $(\tilde{f}_i^h, \tilde{f}_i^m)$  .

On veut également représenter dans les plans discriminants les centres de gravité des classes de  $Y$  correspondant à ses  $q$  modalités. Montrez que ces centres de gravité ont pour coordonnées sur les  $H$  premiers axes discriminants :

$$(Y' W Y)^{-1} Y' W \tilde{F}^H, \text{ où } \tilde{F}^H = [\tilde{f}^1, \dots, \tilde{f}^H]$$

Dans le plan dual, la variable  $x^j$  sera représentée par ses corrélations avec les composantes discriminantes :  $\left( \frac{\langle x^j | f_i^h \rangle_W}{\|x^j\|_W \|f_i^h\|_W}, \frac{\langle x^j | f_i^m \rangle_W}{\|x^j\|_W \|f_i^m\|_W} \right)$  .

## II - Programmation

1. Programmez le calcul des  $H$  premières composantes de l'ADPLS.
2. Programmez le calcul des indicateurs  $S(f)$  et  $R^2(f, Y)$  pour ces  $H$  premières composantes.
3. Programmez le calcul des coordonnées des centres de gravité des  $q$  classes sur les  $H$  axes discriminants.
4. Programmez le calcul des coordonnées des variables de  $X$  .
5. Programmez l'affichage des individus et des centres de gravité de classes dans un plan  $(h, m)$  choisi par l'utilisateur. Programmez l'affichage des variables dans ce plan  $(h, m)$  et faire figurer le cercle unité sur ce graphique.

## III - Application: types forestiers du bassin du Congo

1. Chargez le fichier *genus*. Procédez, avec votre programme, à l'ADPLS exploratoire de la variable  $Y = \text{forest}$  sur les variables de composition arborée  $X = [\text{gen1}, \dots, \text{gen27}]$ , en centrant-réduisant ces dernières variables au préalable et en choisissant la métrique  $M$  adaptée .
2. Interprétez soigneusement les résultats obtenus à partir des indicateurs et des graphiques. Prenez soin de dépasser l'interprétation isolée de chaque composante en interprétant les plans entiers.